

AIを用いたUFMデータによる BOO/DU診断の一考案

董冕雄¹、太田 香¹、顔文豪¹、京田 有樹²、舛森 直哉²

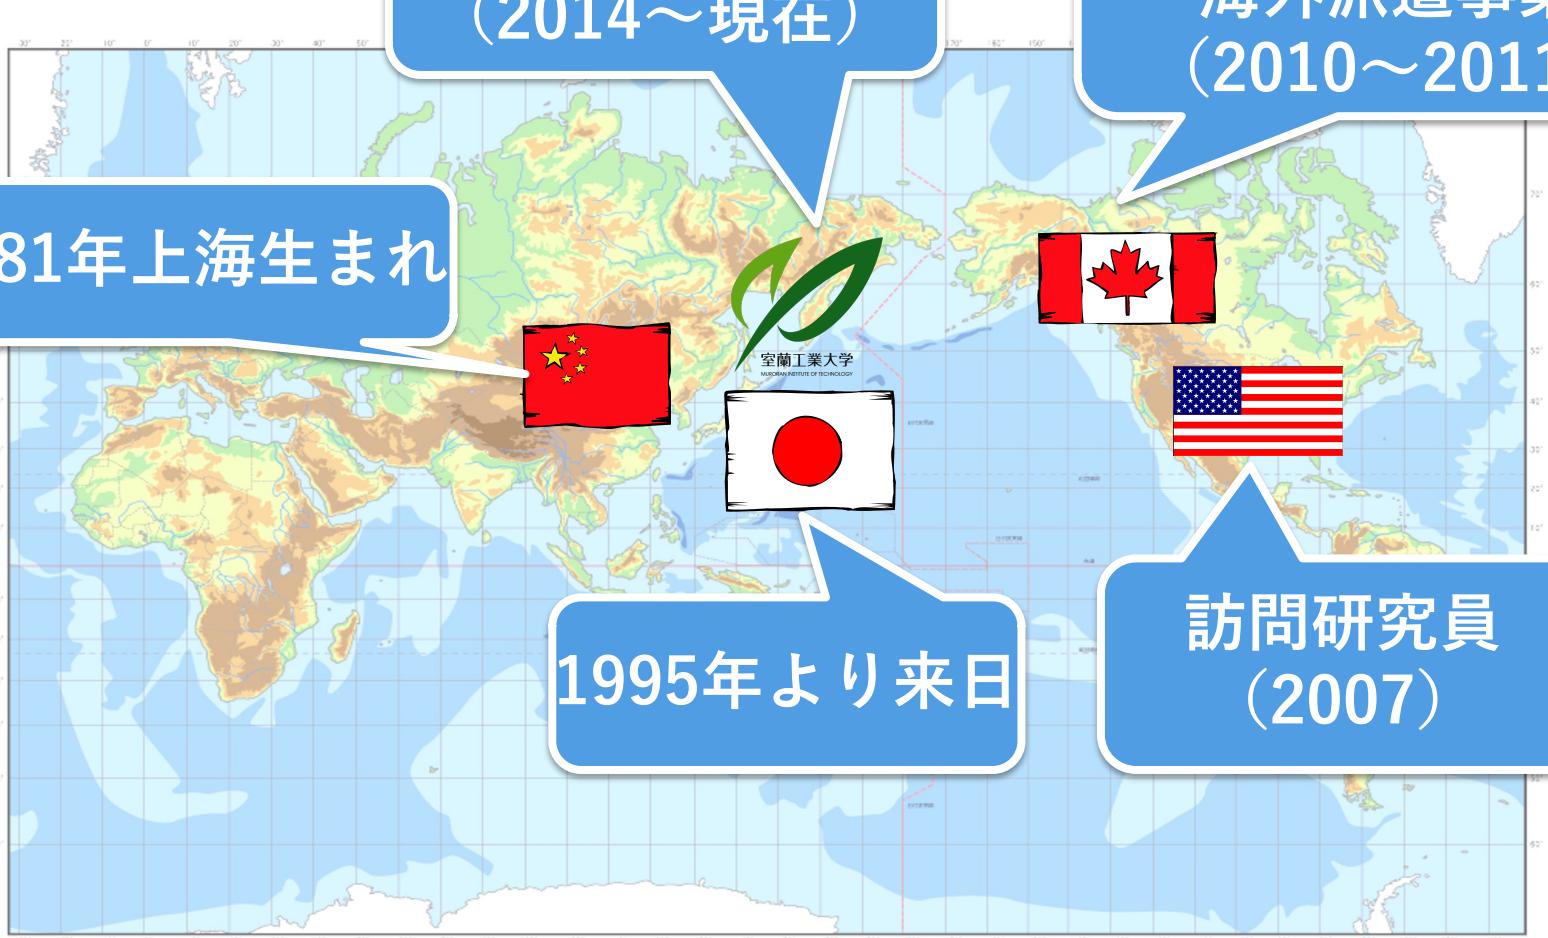
1：室蘭工業大学大学院工学研究科

2：札幌医科大学医学部泌尿器科学講座

経歴



- **董冕雄 教授、副学長**
- BS., MS., Ph.D. (会津大学)
- 専門:コンピュータ科学



研究の専門分野:情報ネットワーク

1. 耐災害支援システムの研究開発

- 最先端の情報技術を生かした、ドローン活用の災害用通信システム
- エッジコンピューティングを活用した、災害時のモバイル端末間通信
- 災害時でも平時と変わらず運用可能な、高信頼IoTアーキテクチャ
- 登別市/紋別市防災訓練において実証実験(2019)
- 室蘭建設業協会の災害対策委員会との連携(進行中)

2. 医工連携

- 医療系教育機関と連携した、画像解析による診断
- AIとエッジコンピューティングを適用した、早期診断システムの提案
- 札幌医科大学・泌尿器科学講座との連携(進行中)

3. Beyond 5G/6Gのための無線ネットワーク技術

- 自動車通信ネットワークシステムの構築
- AIを駆使したインテリジェントIoTシステムの研究
- ミリ波を用いた、無線通信環境の実現

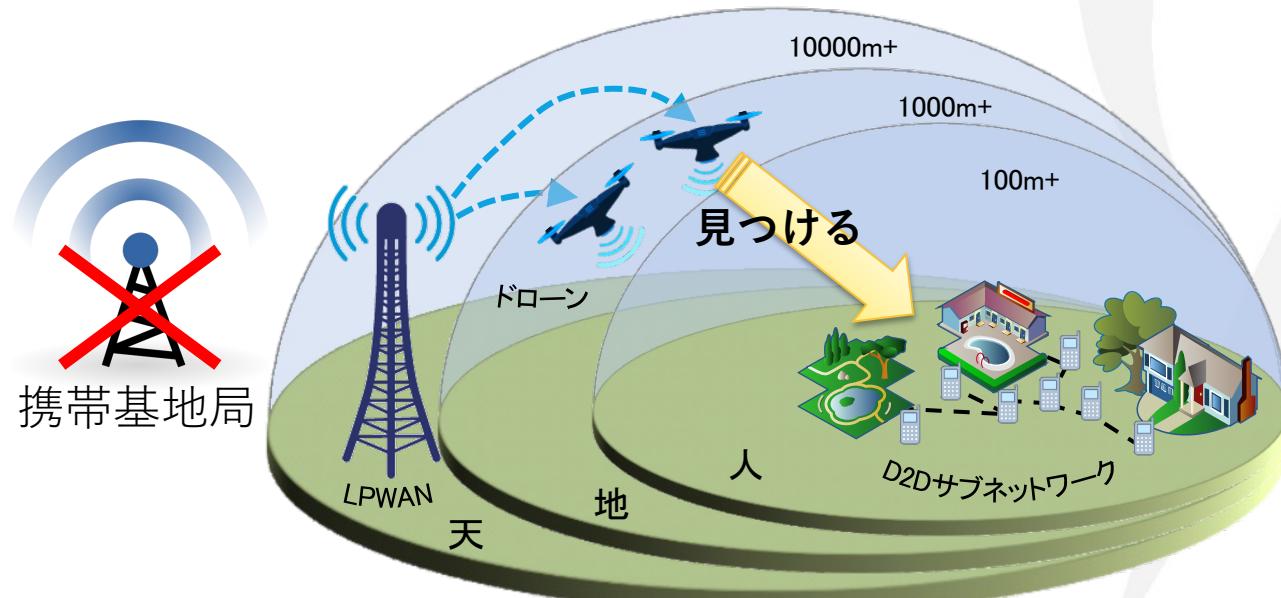
天地人: 次世代災害支援システム

災害発生後即座の通信回線復旧が目的

3つの通信技術により実現 :

- 「天」 : 省エネ広域通信 (LPWAN, Low-Power Wide-Area Network)
- 「地」 : ドローンによる中継 (Wi-Fi)
- 「人」 : 基地局を介さない端末間通信 (D2D通信)

ドローンを臨時基地局として使用



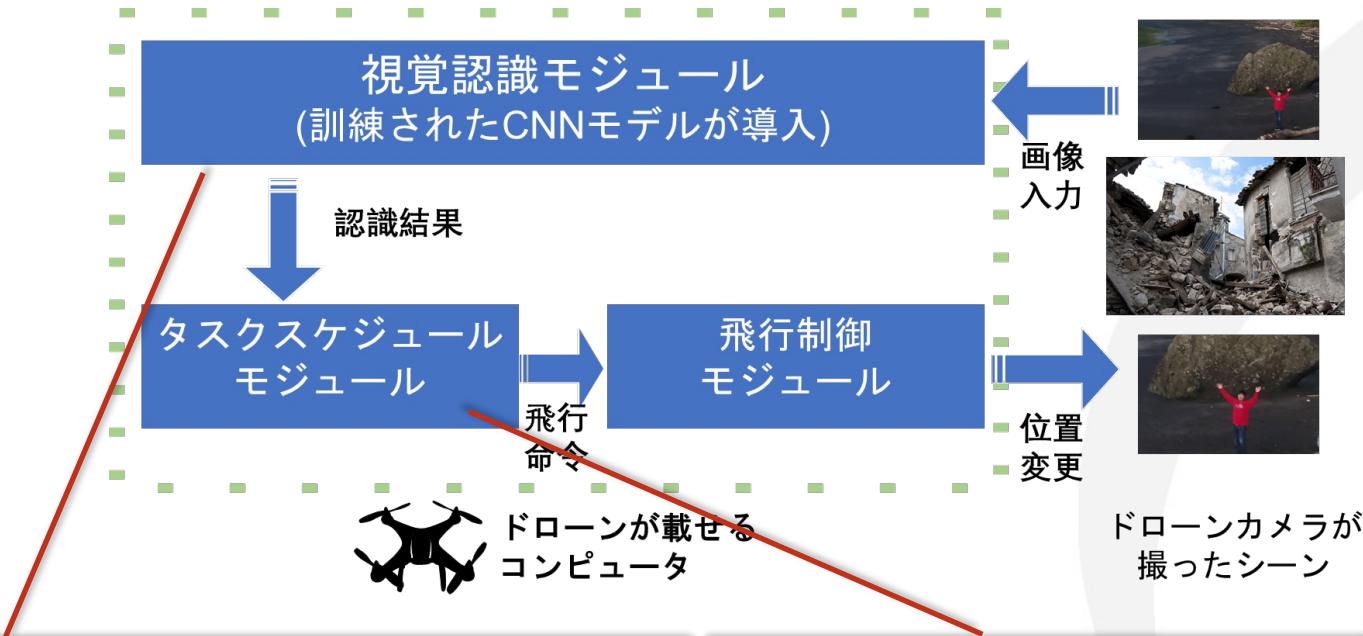
ドローンの自律制御技術

ドローンからターゲットを発見⇒AI技術を使用

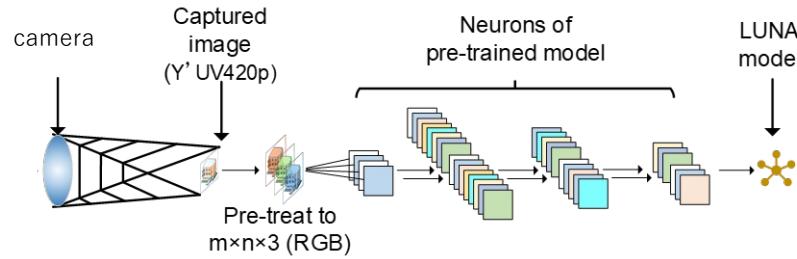


2023/10/26

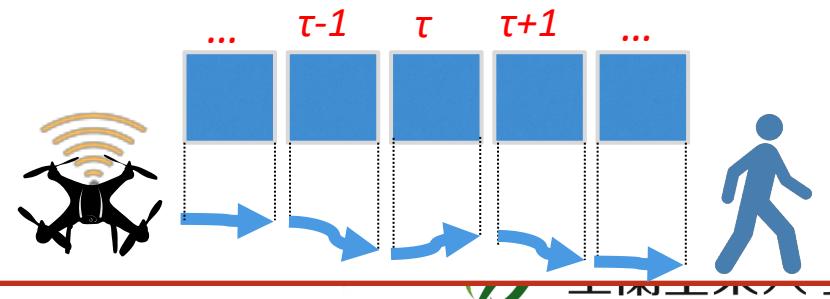
見つける: ユーザ検索と飛行制御



- UAVカメラ画像を処理し、人を発見
- CNNの軽量化・高速化が可能な
MobiNet[※]を適用
- 転移学習によりトレーニング時間の削減とモデルサイズの縮小



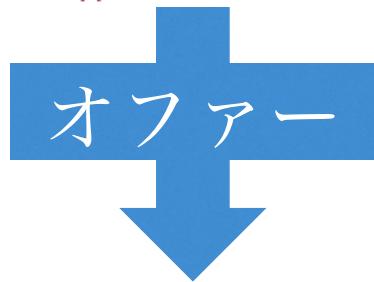
- 認識結果を基に、タスクを決定
- タスク = ドローンの飛行プロセス
(前進/後進、左旋回/右旋回、など)
- 離散時間マルコフ連鎖を用いてドローンのプロセスをモデル化



共同研究のきっかけ

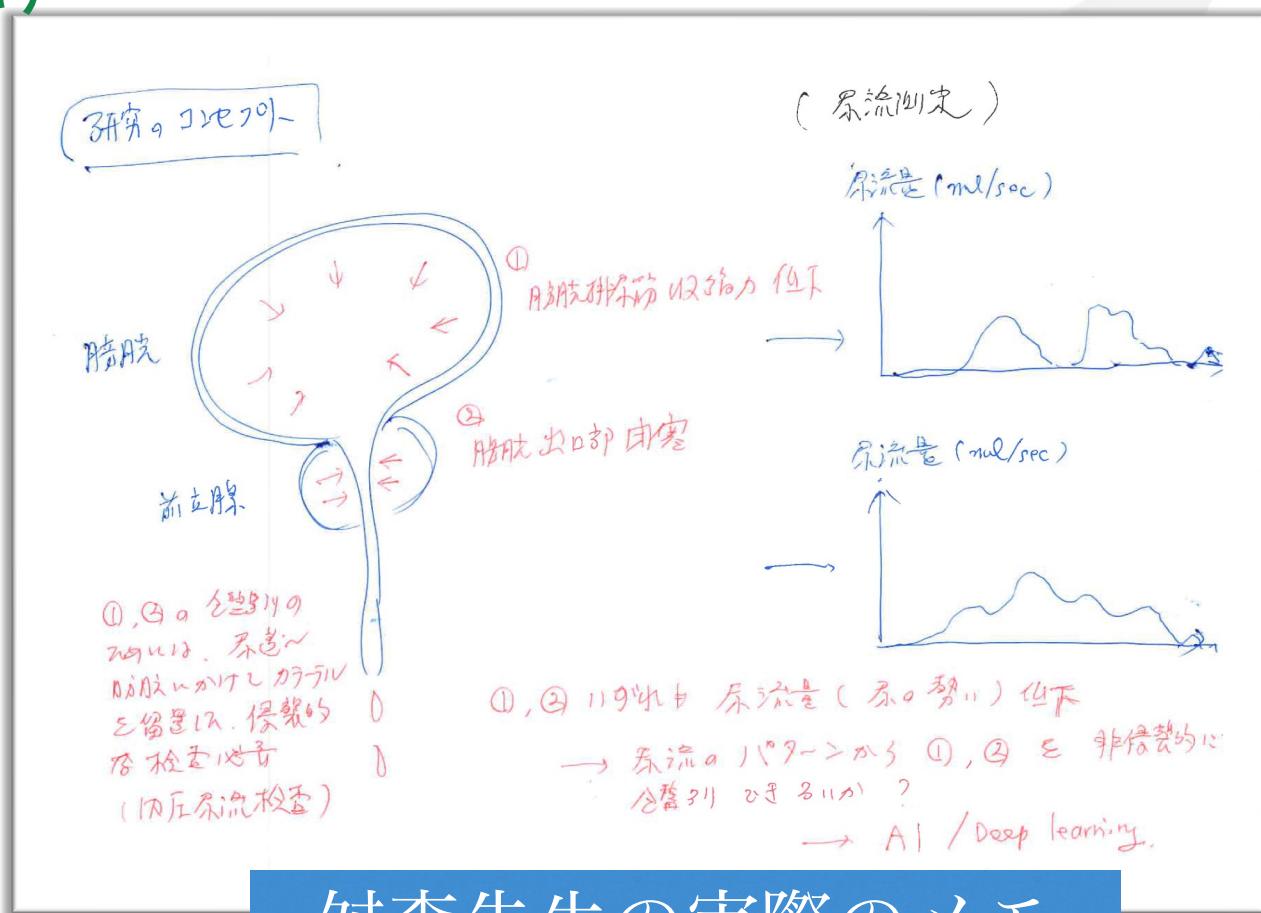


北海道公立大学法人
札幌医科大学
Sapporo Medical University



国立大学法人
室蘭工業大学
MURORAN INSTITUTE OF TECHNOLOGY

AIの専門家ではないが、
知見を活かせれば。。。。

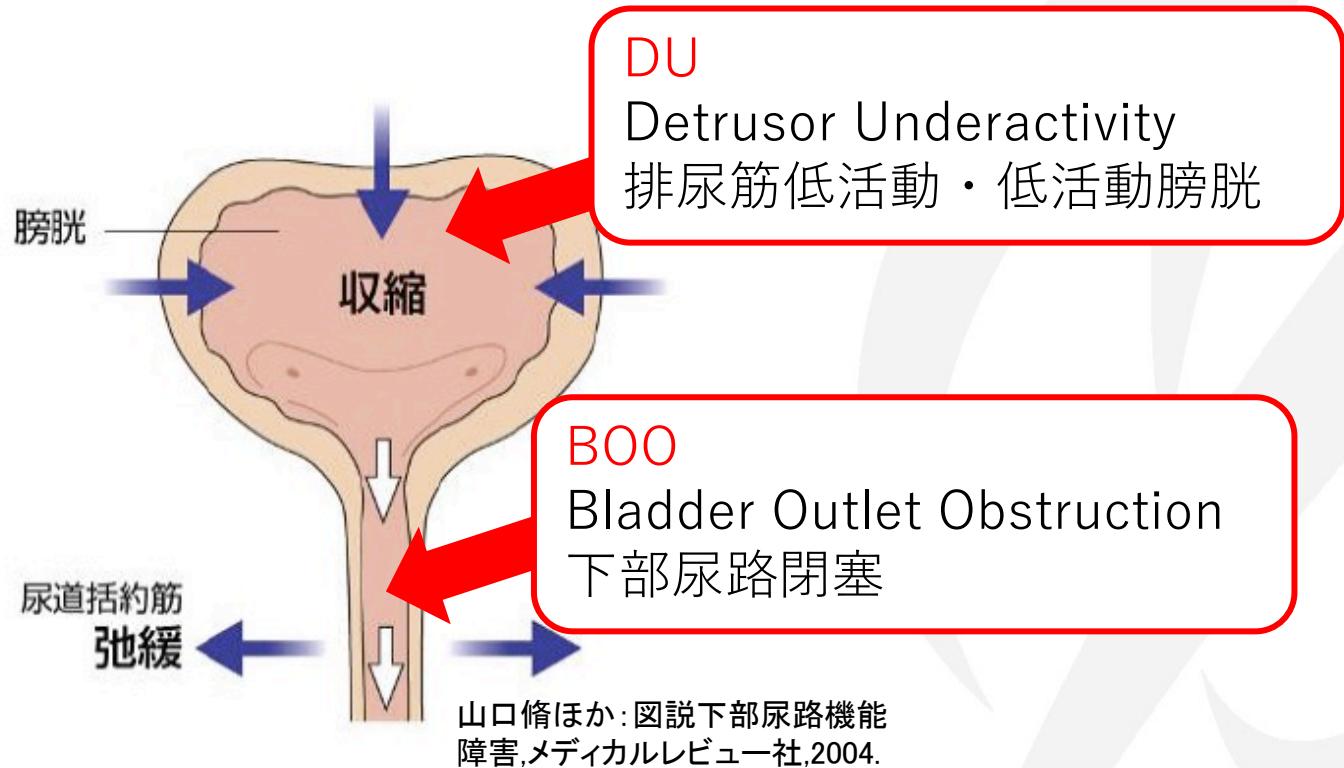


舛森先生の実際のメモ

2020年より舛森教授研究グループとの共同研究を開始

大学

尿勢低下の主要因



その他、本研究での定義

- Normal: BOOもDUもない状態（健常）
- MIX: BOOとDUの両方が存在している状態

尿流検査の問題

- DU/BOOの診断のため、現行の尿流検査は2つ：
 - **UFM** (Uroflowmetry：尿流測定)
 - 通常の排尿と同じ ⇒ **患者に負担少**
 - アウトプット：尿流波形データ
 - **PFS** (Pressure Flow Study：内圧尿流測定)
 - カテーテルを導入し排尿 ⇒ **患者に負担大**
 - アウトプット：数値データ
- 問題点：
 - UFMデータは所見のみで使用
 - 正確な診断には**PFSのデータが必須**
 - **BOOI** (Bladder Outlet Obstruction Index：下部尿路閉塞度)
 - **BCI** (Bladder Contractility Index：膀胱排尿筋収縮度)



目的と方法

- 本研究の目的
 - 負担の少ないUFMのデータだけで、Normal/BOO/DU/MIXを判断し、体に負担のかかるPFSを回避する方法を検討
- 達成方法
 - AI（機械学習や深層学習）を使用し、UFMデータを分類



入力：
UFMデータ

出力:
Normal/BOO/DU/MIX

この研究の難しさ

ビッグデータとAIがあれば、全て解決！
では、残念ながらありません。



• チャレンジ1：データ数が少ない

- ビッグデータ=596サンプル
- PFSデータの多量取得が困難(1年で43データ増)
- UFMデータのデジタル化およびフォーマットが必要

• チャレンジ2：学習のさせ方に工夫が必要

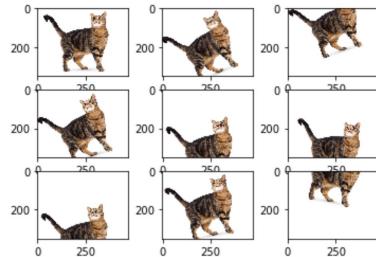
- UFMの波形は見た目がそつくり
- PFSデータも境界付近に多くのデータが存在するため、切り分け困難

チャレンジ1：データ数が少ない 対処法：データの修正

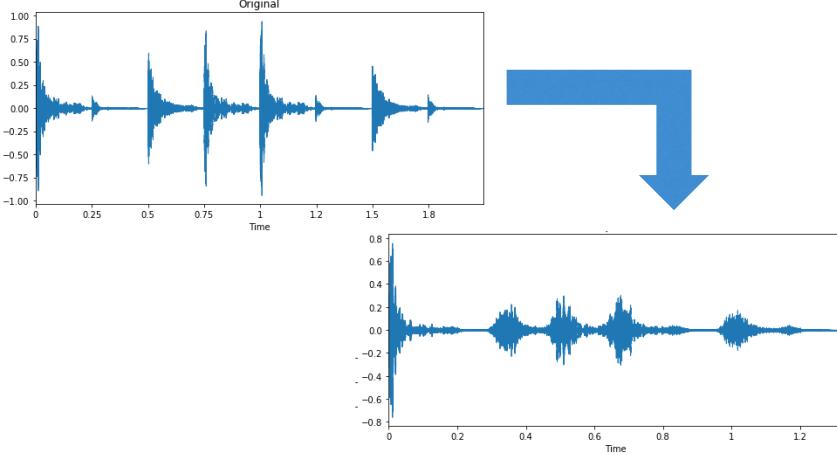
2023/10/26

よくあるデータ拡張方法

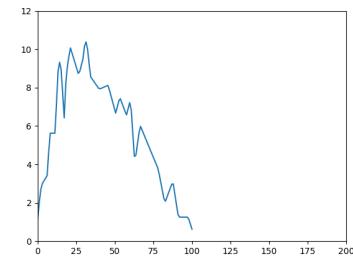
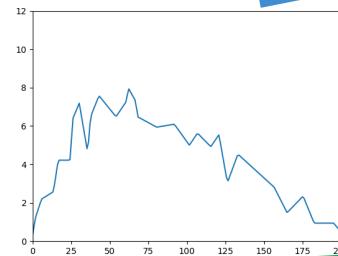
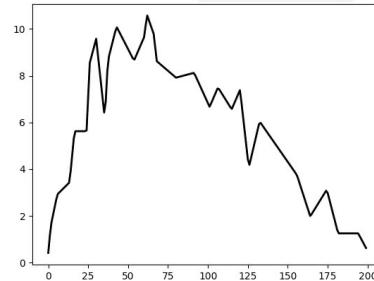
- 画像の例:



- 音声の例:



- UFMデータの例:



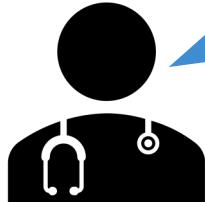
同じように分類されるか？？

適用できず

研究用データ

- 2022年9月現時点のもの
- 総データ数: 596
- Normal:206, BOO:90, DU:236, MIX:64
- 取得期間:2014年1月～2021年8月
- 対象年齢:88歳～38歳
 - 80代:40人、70代:268人、60代:243人、50代:42人、50代以下:3人
- 性別:男性
- UFMデータ:画像、数値
- PFSデータ:数値

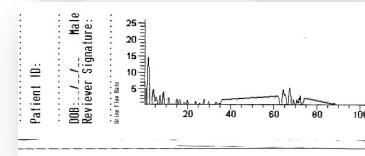
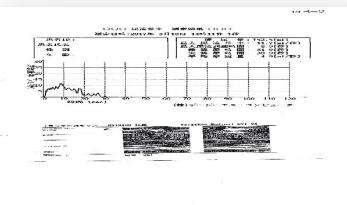
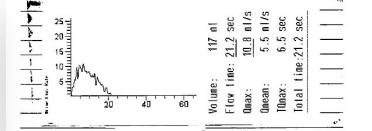
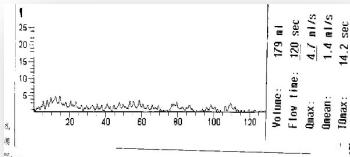
データ収集の苦労



京田先生

- PFSは検査の解釈が難しい検査で、検査結果を一つ一つ再確認（クリーニング）して、より正確なデータにした。
- 当初700例を越える検査データがあったが、最終的には500例強のデータを使用した。

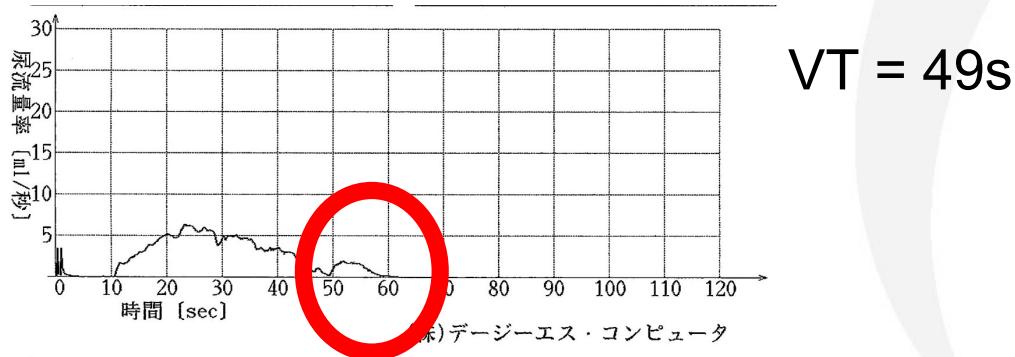
- 紙のUFMデータをスキャンし、画像化
- さらにUFMデータから数値おこし



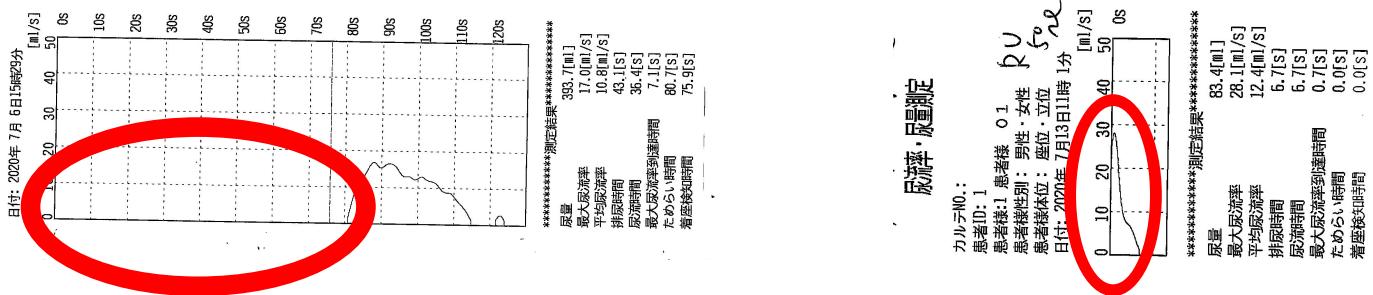
No	年齢	MCC	compliance	Qmax	PdetQmax	PabdMax	間欠腹圧	BCI	BCI 0<100, 1>100	BOOI	BOOI 0<40, 1>40	病型	Schafer BOO	Schafer Contractility	VV	Qmax	Qave	PVR	VT	Sawtooth& interrupted	UFM type 0:S, 1:P, 2:D
U0023	71	387	38.7	6.9	79	0	0	113.5	1	65.2	1	BOO	4	N-	117	10.8	5.5	0	21.2	0	1
U0030	70	794	72.1	11	118	55	1	173	1	96	1	BOO	4	ST	46	6.9	2.7	207	19.7	0	1
U0042	61	512	23.2	15	24	58	1	99	0	-6	0	DU	0	W+	267	45.2	29.6	3	9.2	0	1
U0044	75	449	40.8	4	36	68	1	56	0	28	0	DU	1	W-	236	7.8	2.9	171	82.7	1	1
U0045	69	568	9.3	10.8	54	0	0	108	1	32.4	0	Normal	2	N-	342	15.6	5.7	162	77.2	1	1
U0046	78	300	17.6	1.2	59	62	1	65	0	56.6	1	MIX	4	W-	179	4.7	1.4	76	128	1	1
U0047	75	389	12.5	12.7	53	0	0	116.5	1	27.6	0	Normal	2	N-	113	5.8	2.7	12	52.7	0	1
U0048	77	449	56.1	3.7	35	0	0	53.5	0	27.6	0	DU	2	W-	49	3.1	1.1	0	55	1	1
U0049	63	651	217	13.7	44	0	0	112.5	1	16.6	0	Normal	1	N-	299	25.1	12.5	0	24.5	0	1
U0052	61	451	90.2	12.5	40	0	0	102.5	1	15	0	Normal	1	N-	148	21.9	9.5	13	21.2	0	1

実は、研究初期の頃…

- 欠陥データと判断したものを削除
 - 全587件、ノイズにより除去234件、実際使用353件
- ケース1：UFM曲線と数値データが不一致なサンプル



- ケース2：サンプリング方法が明らかに他のサンプルとかけ離れている

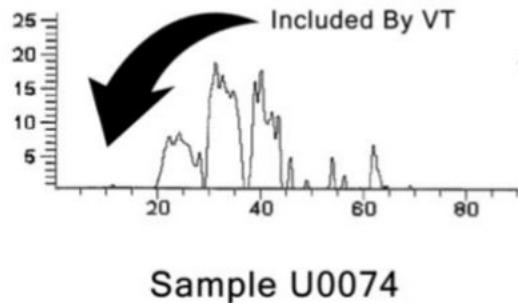


データ修正によりデータ数増加

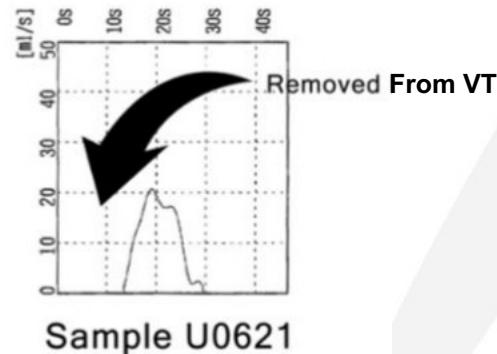
- 原因解説:

- その1: 測定機種によって、開始時間にバラツキ
 - 自動操作 vs 人による操作
 - 出力形式が若干異なる
- その2: VTの数値化が未統一

VTに遅延時間を含む



VTに遅延時間が含まれない

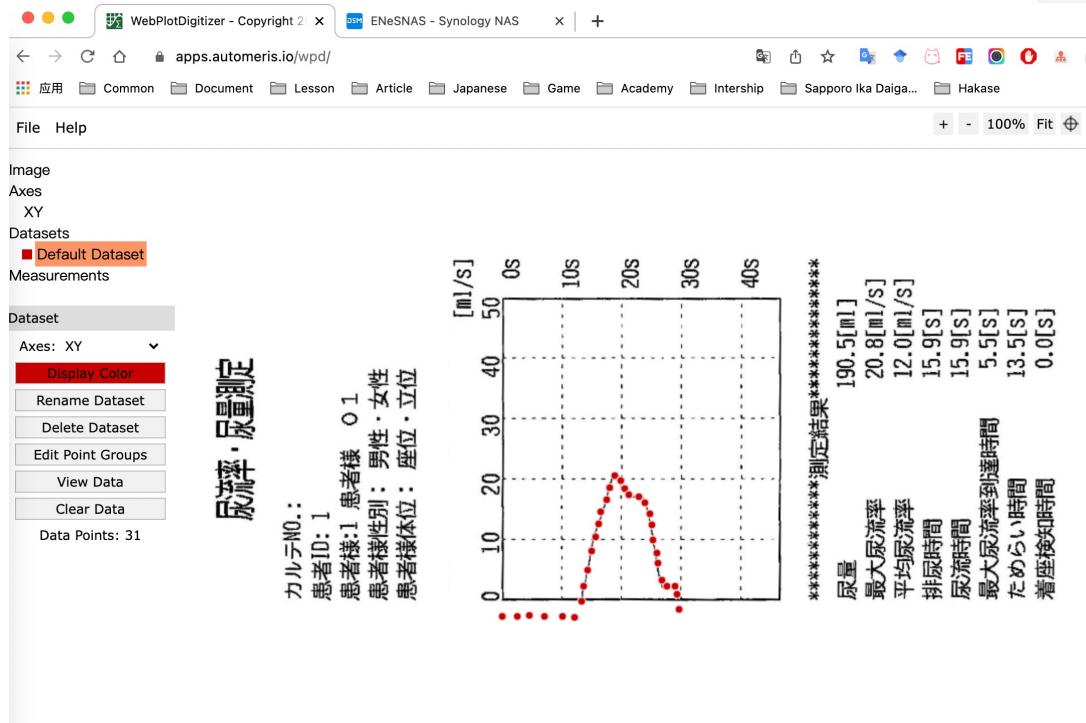


- 解決方法:

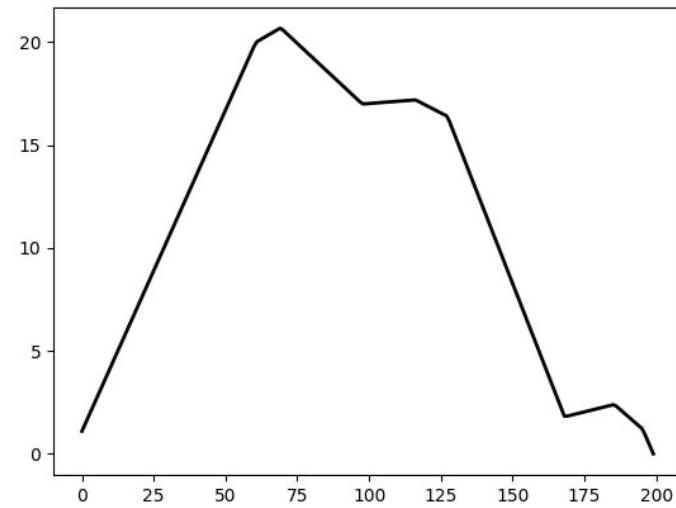
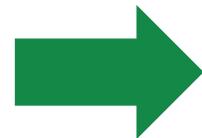
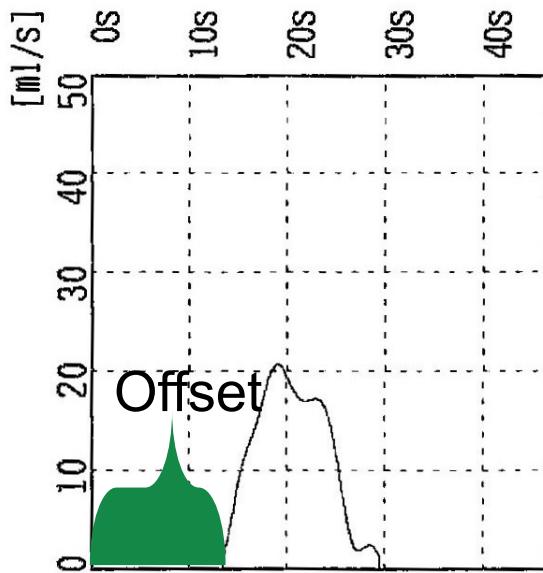
- 遅延時間を波形データから除去し、波形を再描画
- VTの値を再取得

波形データの再描画

- オンラインツール「Web Plot Digitizer」を使用
 - <https://automeris.io/WebPlotDigitizer/>
 - 画像のグラフから数値を取得できるツール
- 手作業で1つずつサンプリング



遅延時間を削除し、再描画



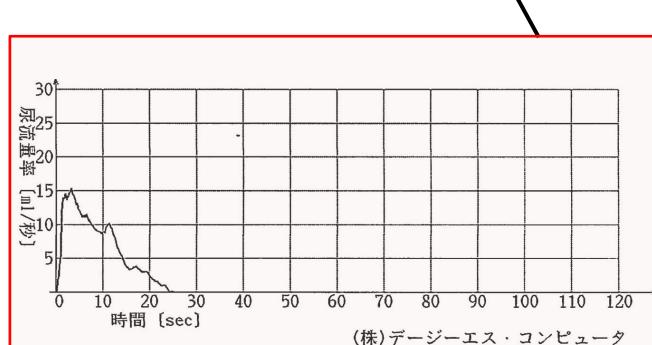
- パラメータの数値修正
- $$VT = VT - Offset$$
- $$Xseries = Xseries - Offset$$

チャレンジ2：学習のさせ方に 工夫が必要 対処法：モデルの選定

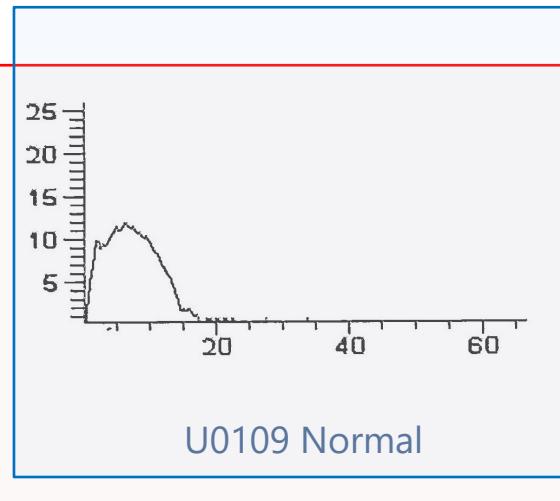
2023/10/26

見た目がそっくりな
UFMデータ

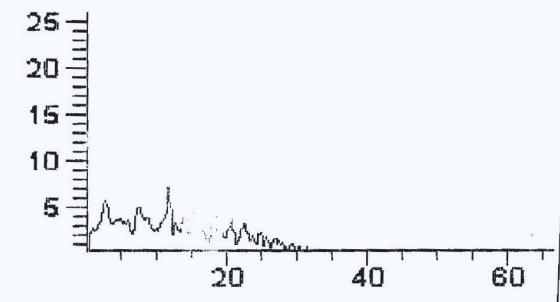
明らかに違いが分か
るUFMデータ



U0136 BOO



U0109 Normal



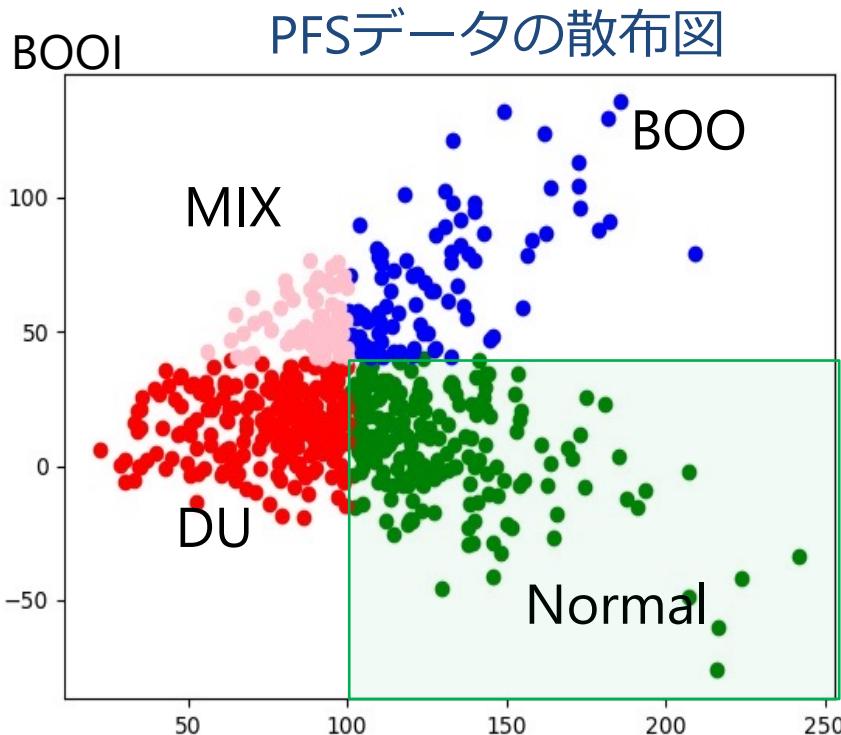
U0192 BOO

機械も「見た目」で類似度を判断

学習がうまくできない理由の例：

- U0136(BOO)をBOOと学習する ⇒ U0109(Normal)をBOOと誤検知
- U0192(BOO)をBOOと学習する ⇒ U0136(BOO)をNormalと誤検知
- U0109(Normal)をNormalと学習する ⇒ U0136(BOO)をNormalと誤検知

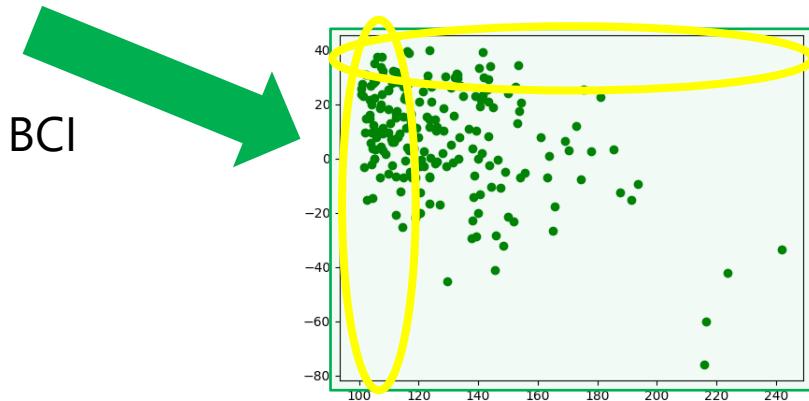
- 各境界に多くのデータがあるため、4つのタイプを簡単に区別（学習）できない



具体例：205件のNormal
サンプルのうち

	境界	それ以外
No.	102	103

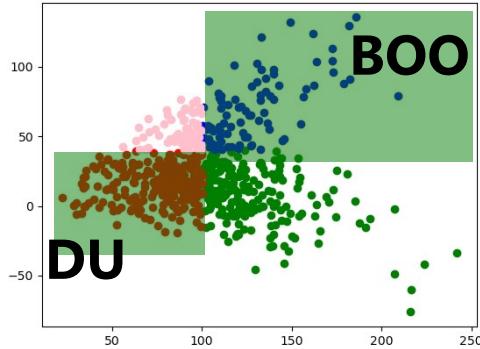
境界データ：
 $100 < \text{BCI} < 120$ または $32 < \text{BOOI} < 40$



既存研究(BOO/DUの2分類)

概要:

- ICS 2019 Gothenburgで発表
- BOOとDUの2分類のみ対応



UWE Bristol
International Society of Continence
ICS 2019 GOTHENBURG
Bristol Urological Institute

Detrusor underactivity (DU) vs bladder outlet obstruction (BOO)

- Bothers up to one-third of elderly male patients [1]
- Pressure flow studies used to diagnose
- DU and BOO cannot be differentiated non-invasively
- Normal detrusor contraction or weak contraction with abdominal straining
- Can these be differentiated based on free flow data?
- Several non-invasive indicators proposed, but with limited diagnostic accuracy

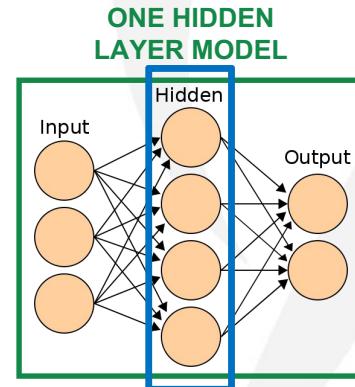
Aim: non-invasively differentiate DU from BOO using Neural Network model

1. Urine flow rate curve shape
2. Parameters derived from free flow rate data – time and frequency domain analysis

1. Osman, N.I. et al. Eur Urol. 2014;65: 389-398

ICS 2019 GOTHENBURG
3-6 September

- UFMデータの波形の類似性から分類
- データ数が少なく、過学習を防ぐため、一層のニューラルネットワークを適用
⇒多層構造になるほど、学習能力が高いため。
⇒データ数が少ないと、汎用性が失われる可能性あり



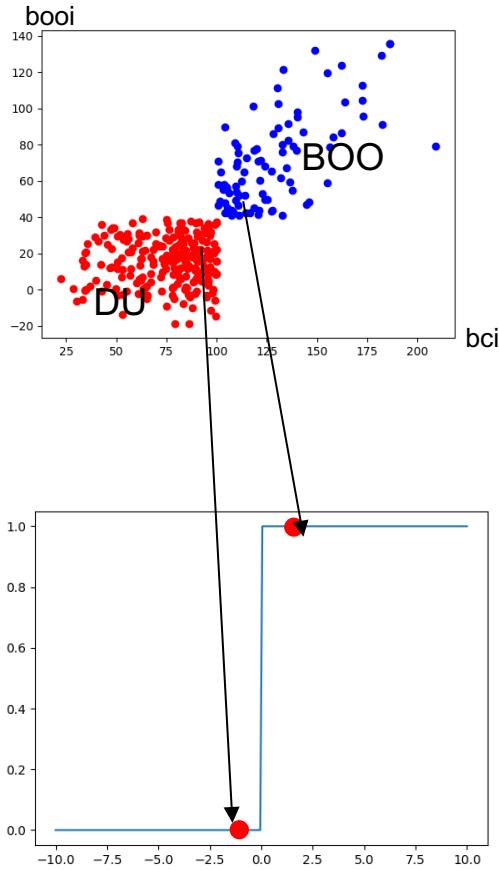
検証結果

Dataset	BOO	DU
N	158	135

70.6% overall accuracy

2値分類は比較的容易

- BOOとDUの境界は明らか

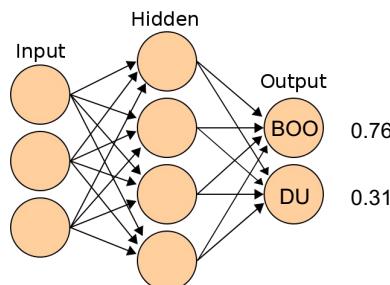


- 0か1で表現できる

Sample	DU	BOO
Sample 1	1	0
Sample 2	0	1
Sample 3	1	0

活性化関数：ニューラルネットワークの出力を最終決定する関数

$$\text{Softmax}(x_i) = \frac{\exp(x_i)}{\sum_j \exp(x_j)}$$



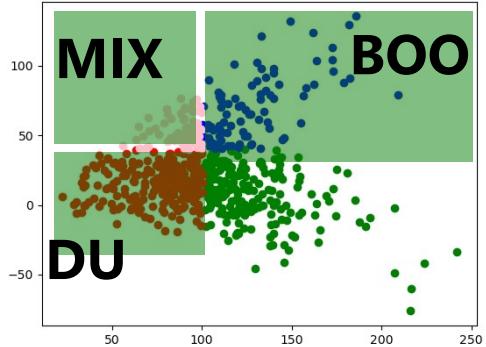
$$P_{BOO} = \frac{e^{0.76}}{e^{0.76} + e^{0.31}} \approx 0.61$$

$$P_{DU} = \frac{e^{0.31}}{e^{0.76} + e^{0.31}} \approx 0.39$$

既存研究(BOO/DUの3分類)

概要:

- International Journal of Urology, 2021で発表
- BOO/DU/MIXの3分類に対応



- UFMデータからBCIとBOOIの数値を予測後、分類
- 一次元畳み込みニューラルネットワーク(1D CNN)を採用
- CNNは主に画像認識で使用される深層学習の代表
- 1Dは主に時系列データを扱うときに使用

INTERNATIONAL JOURNAL OF UROLOGY
International Journal of Urology (IJU)

Check for updates
doi: 10.1111/iju.14661

Original Article: Clinical Investigation

Development of an artificial intelligence diagnostic system for lower urinary tract dysfunction in men

Yoshihisa Matsukawa,¹ Yoshihiko Kameya,² Tomoochi Takahashi,³ Atsuki Shimazu,² Shohei Ishida,¹ Muneyo Yamada,² Naoto Sasaki,² and Tokunori Yamamoto^{3,4}

¹Department of Urology, Nagoya University Graduate School of Medicine, Nagoya, Aichi, ²Department of Information Engineering, Graduate School of Science and Technology, Meijo University, Nagoya, Aichi, ³Meis Technology Inc., Nagoya, Aichi, and ⁴Department of Urology, Aichi Medical University School of Medicine, Nagakute, Aichi, Japan

Abbreviations & Acronyms

1-D = one-dimensional
AI = artificial intelligence
BCI = bladder contractility index
BOO = bladder outlet obstruction
BOOI = bladder outlet obstruction index
BVI = bladder voiding efficiency
DU = detrusor underactivity
ICSI = International Continence Society
IPSS = International Prostate Symptom Score
LUTS = lower urinary tract dysfunctions
OABSS = Overactive Bladder Symptom Score
PFS = pressure flow study
PSA = prostate-specific antigen
PVR = post-void residual
 Q_{max} = maximum flow rate
QOL = quality of life
SD = standard deviation
UAB = ultrasound bladder
UDS = urodynamic studies
UFM = uroflowmetry

Objectives: To establish an artificial intelligence diagnostic system for lower urinary tract function in men with lower urinary tract symptoms using only uroflowmetry data and no evaluation of urodynamics.

Methods: Uroflowmetry data of 256 treatment-naïve men with detrusor underactivity, bladder outlet obstruction, or detrusor underactivity + bladder outlet obstruction were used for artificial intelligence learning and validation using neural networks. An optimal artificial intelligence diagnostic model was established using the original data set, cross-validation and data augmentation. Correlations of bladder contractility index and bladder outlet obstruction index values for the artificial intelligence system and pressure flow study values were examined using Spearman's correlation coefficient. Additionally, diagnostic accuracy was compared between the artificial intelligence system and a urologist who had trained urologists with uroflowmetry data of 25 additional patients by χ^2 -tests. Detrusor underactivity was defined as bladder contractility index <100 and bladder outlet obstruction index >40 , bladder outlet obstruction was defined as bladder contractility index <100 and bladder outlet obstruction index >40 , and detrusor underactivity + bladder outlet obstruction was defined as bladder contractility index <100 and bladder outlet obstruction index >40 .

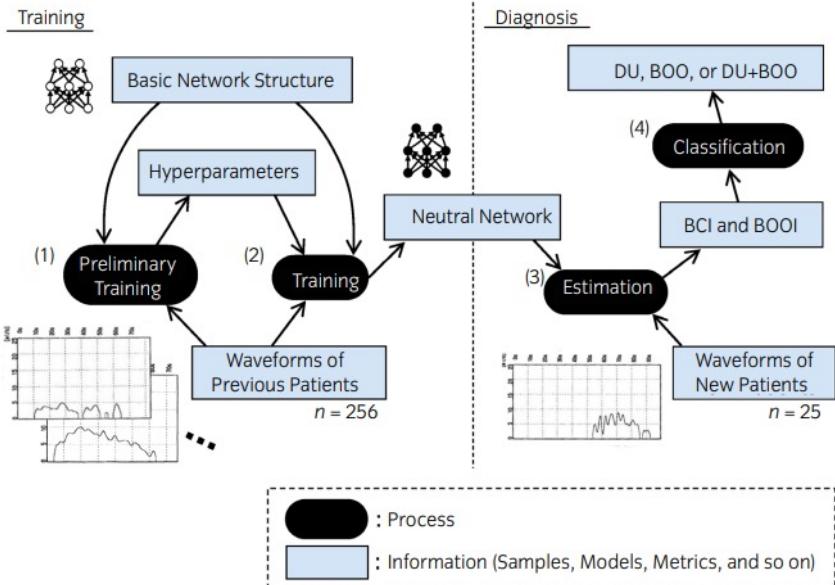
Results: The artificial intelligence system predicted bladder contractility index and bladder outlet obstruction index values showed significant positive correlations with pressure flow study values (bladder contractility index: $r = 0.60$, $P < 0.001$; bladder outlet obstruction index: $r = 0.48$, $P < 0.001$). The artificial intelligence system's detrusor underactivity diagnosis had a sensitivity and specificity of 79.7% and 88.7%, respectively, and those for bladder outlet obstruction diagnosis were 76.8% and 84.7%, respectively. The artificial intelligence system's average diagnostic accuracy was 84%, which was significantly higher than that of urologists (60).

Conclusions: Our artificial intelligence diagnostic system developed using the uroflowmetry waveform distinguished between detrusor underactivity and bladder outlet obstruction with high sensitivity and specificity in men with lower urinary tract symptoms.

Key words: artificial intelligence, deep learning, detrusor underactivity, lower urinary tract dysfunction, urodynamics.

Correspondence: Yoshihisa Matsukawa, M.D., Department of Urology, Nagoya University Graduate School of Medicine, Showa-ku, Nagoya, 466-8550, Japan. Email: yoshihisa@med.nagoya-u.ac.jp
Received: 12 May 2021; accepted: 12 July 2021.

© 2021 The Japanese Urological Association



検証結果

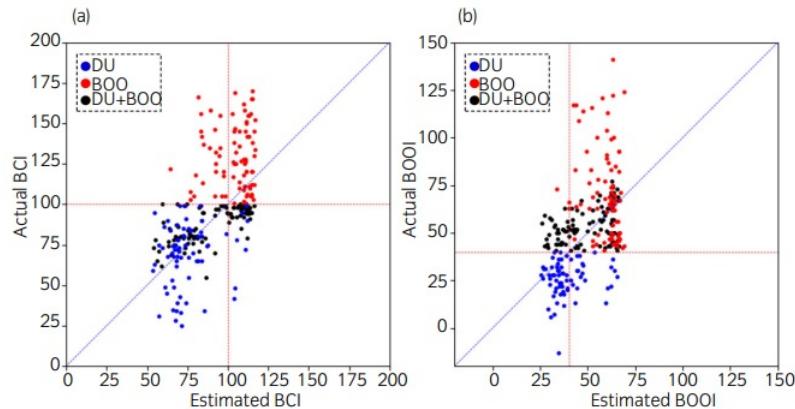


Table 2 Actual diagnosis and AI diagnosis of DU, BOO and DU + BOO

Actual diagnosis	n	AI diagnosis		
		DU n (%)	BOO n (%)	DU + BOO n (%)
DU	79	63 (79.7)	7 (8.9)	9 (11.4)
BOO	112	3 (2.7)	86 (76.8)	23 (20.5)
DU + BOO	65	17 (26.2)	15 (23.1)	33 (50.8)



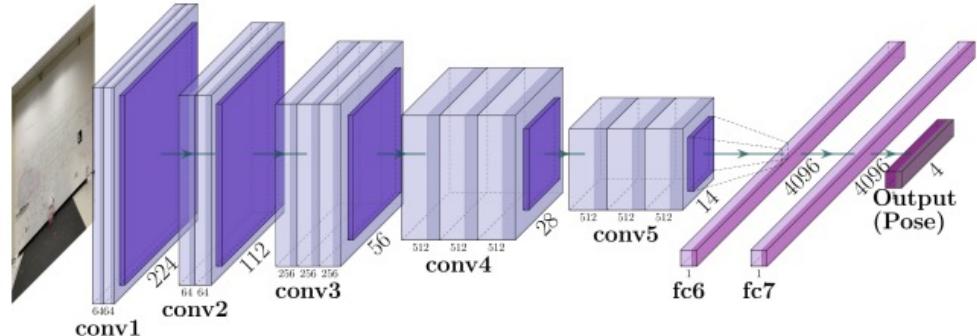
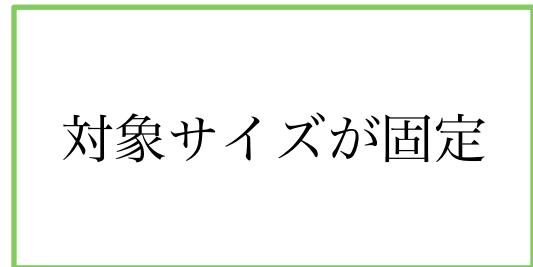
MIXの分類はやはり難しい

私達のゴール：

- Normal/BOO/DU/MIXの4分類を実現したい

私達の提案：再帰型ニューラルネットワークの適用

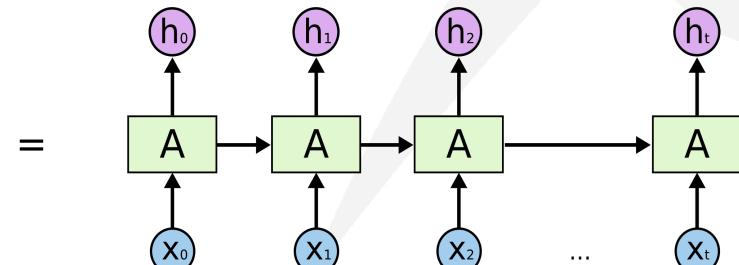
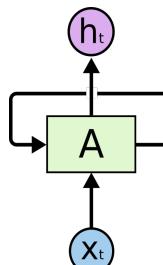
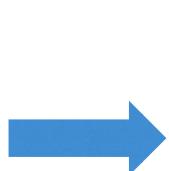
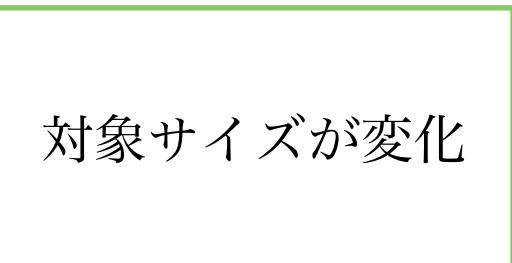
DNNやCNNなど



⇒UFMデータの場合、すべてのサイズを合わせる必要あり

例：140秒で切り取り、一律化

再帰型ニューラルネットワーク (RNN、LSTMなど)

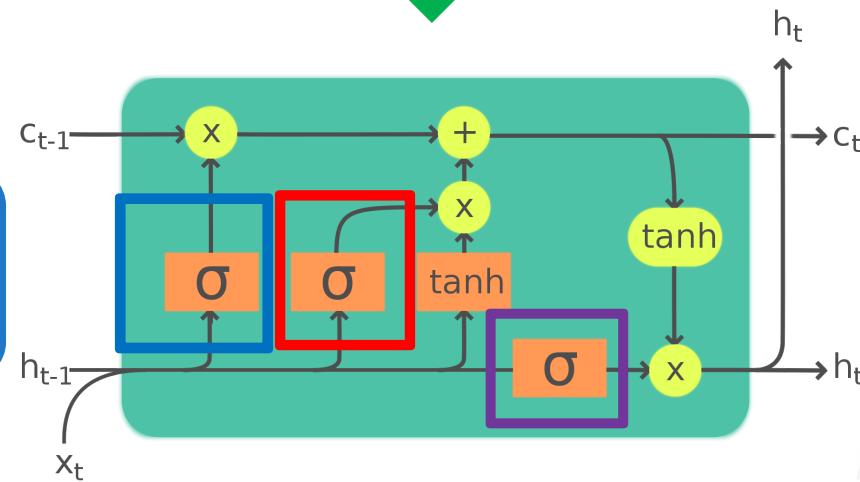
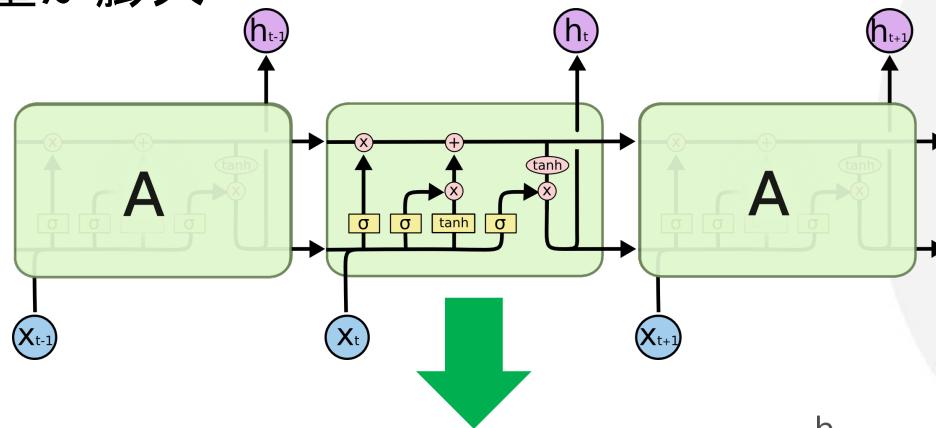


⇒自然言語処理や時系列データに最適

UFMデータを切り取る必要なし

LSTM(Long Short Term Memory)とは

- ニューラルネットワークに使用される層
- 時系列データを扱うRNNを改良し、長期的特徴と短期的特徴を同時に学習可能
- 欠点は計算量が膨大



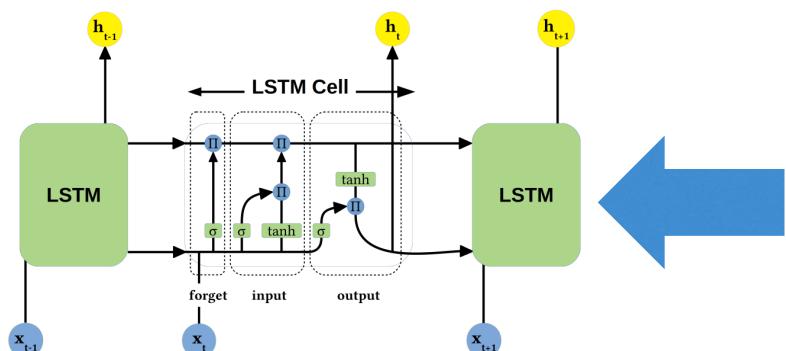
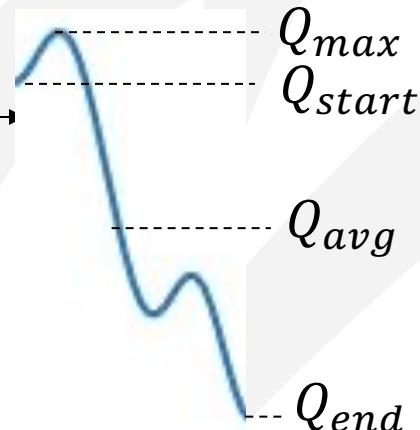
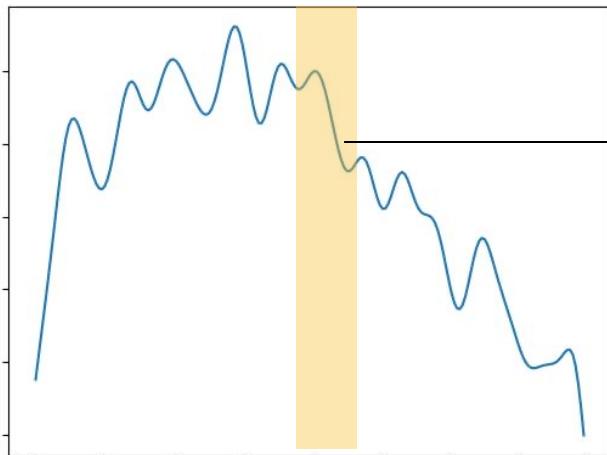
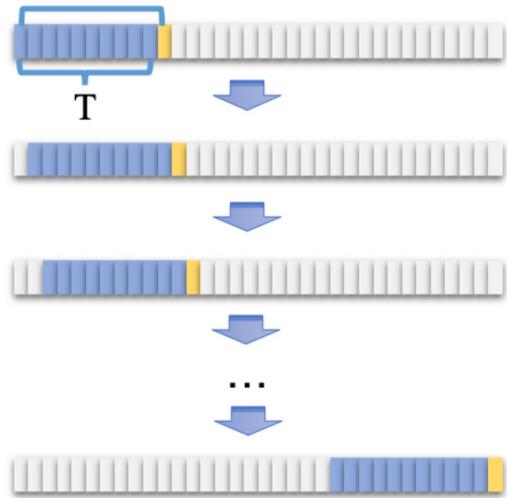
忘却ゲート
セル状態から捨てる
情報の判定に使用

出力ゲート
セル状態のどの
部分を出力する
かを判定

入力ゲート
どの値を更新す
るか判定するの
が主な役割

UFMデータとLSTM

Sliding window

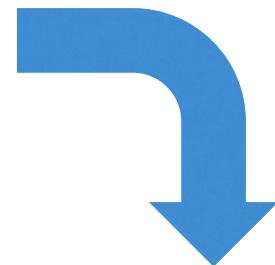
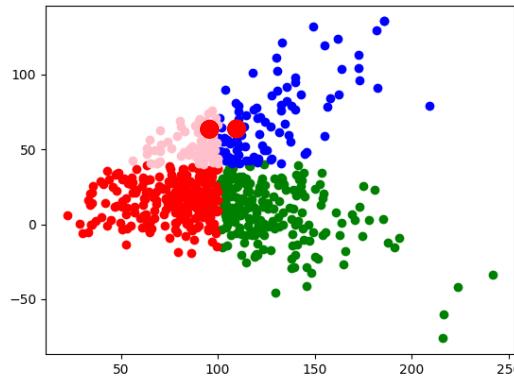


$$X_t = [Q_{end} - Q_{start}, Q_{avg}, Q_{max} - Q_{avg}]$$

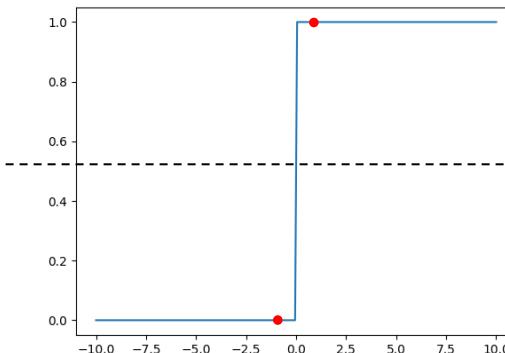
活性化関数

シグモイド関数を適用し、境界データの分類を最適化

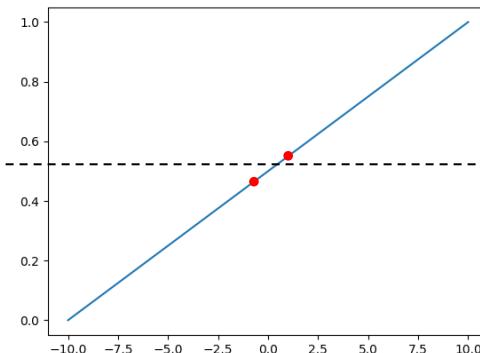
※あらゆる入力値を0.0~1.0の範囲の数値に変換して出力する関数



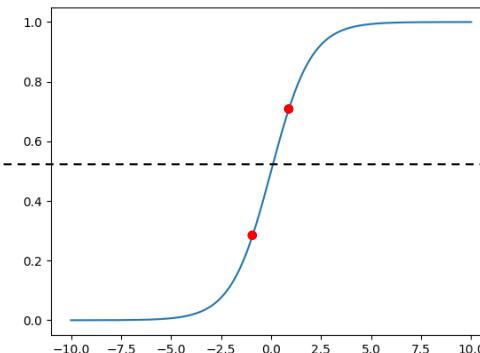
$$f(x) = \frac{1}{1 + e^{-(x)}}$$



DU/BOO
(2値分類、ステップ関数)



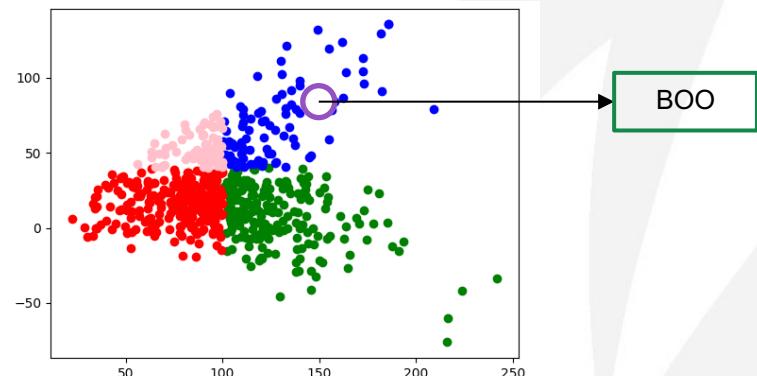
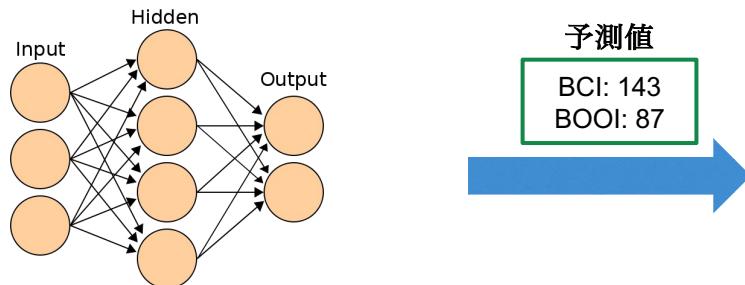
DU/BOO/MIX
(3分類、線形)



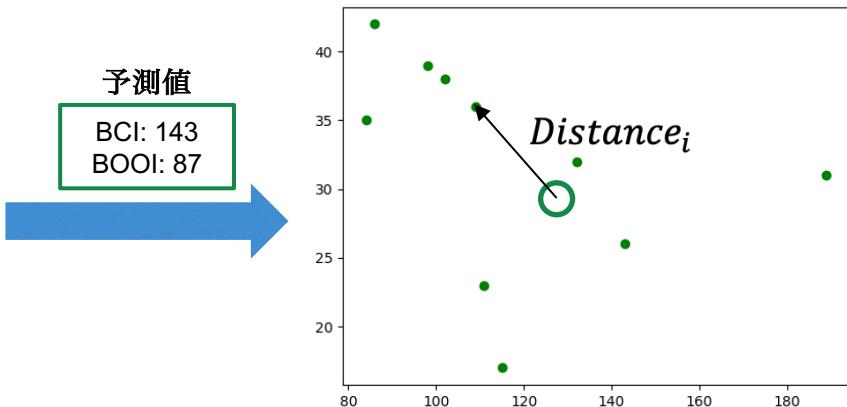
DU/BOO/MIX/Normal
(4分類、シグモイド)

予測値から分類の工夫

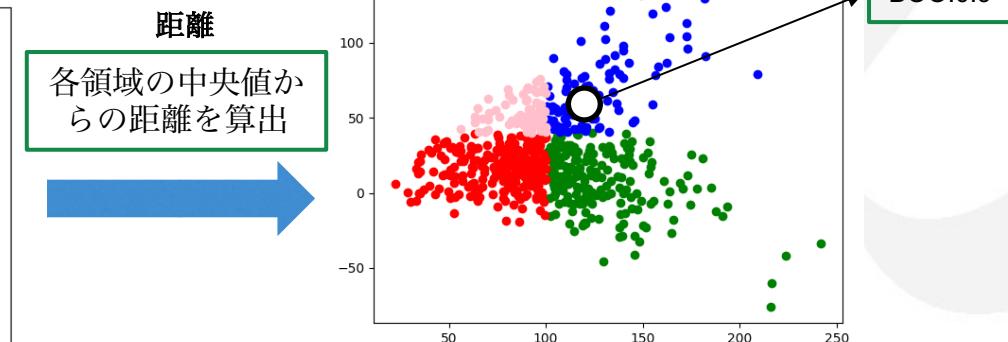
- 通常のやり方:



- 私達のやり方:



$$Distance_{i,type} = \sqrt{(x_i - x_{type})^2 + (y_i - y_{type})^2}$$



$$P_{i,type} = \frac{\log e^{-1} D_{i,type}}{\sum_{type \in \{Normal, BOO, DU, MIX\}} \log e^{-1} D_{i,type}}$$

検証結果

- 総数: 596 (Normal:206, BOO:90, DU:236, MIX:64)
- 訓練データ: 496、テストデータ: 100

	num	Normal	BOO	DU	MIX
Normal	30	20 (66.7%)	3	5	2
BOO	20	4	14 (70%)	2	0
DU	35	5	2	24 (68.6%)	4
MIX	15	3	3	0	9 (60%)

まとめと今後の展望

【目的】負担の少ないUFMのデータだけで、Normal/BOO/DU/MIXを判断し、体に負担のかかるPFSを回避したい

【方法】AI(機械学習や深層学習)を使用して、4分類する方法を検討

【問題点と解決法】

1. データ数が少ない

- AIで常用のデータ拡張方法が適用不可
- 地道なデータ修正によりデータ数確保

2. 学習のさせ方に工夫が必要

- UFMデータの分類は機械にも困難⇒境界線付近に多数データ
- 既存研究では、2分類(BOO/DU)と3分類(BOO/DU/MIX)まで検討
- 再帰ニューラルネットワークであるLSTMを適用した4分類手法を提案
- 実験結果から、4分類すべてにおいて60%以上のAccuracyを達成

【今後の展望】

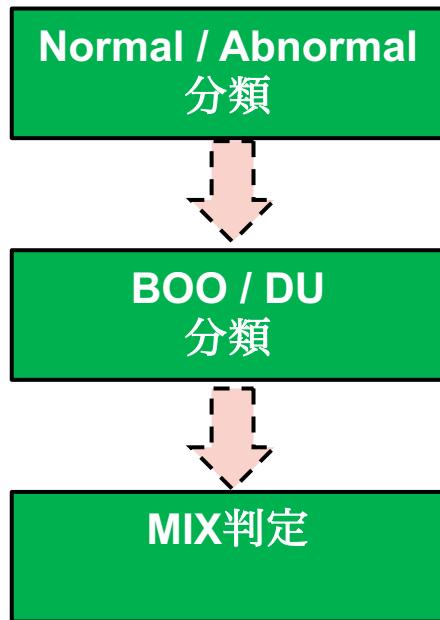
- 分類精度の向上
- デジタルデータの取得

番外編

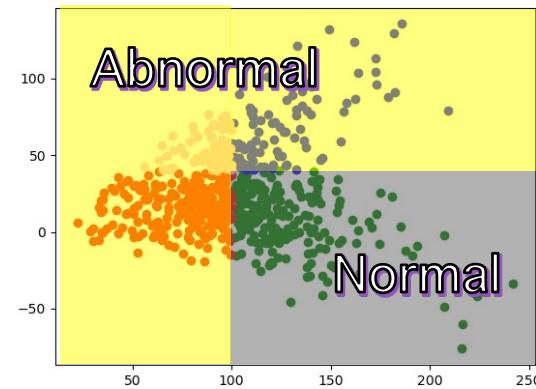
紆余曲折をへて前述の方法にたどり着きました

当初のアプローチ

1. Normal(正常)/Abnormal(病気)を分類
 - 最初から4つの分類は困難



Normalはどのようなデータか学習させる

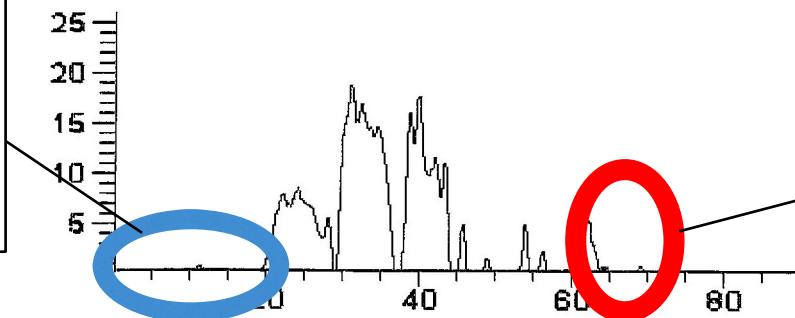


2. データ数が少ないので単純な機械学習で分類
 - SVM(Support Vector Machine)と呼ばれる機械学習を適用

SVMを使うためにUFMデータから特徴量抽出

Delay

尿流量が初めて最大値の20%に達した時間

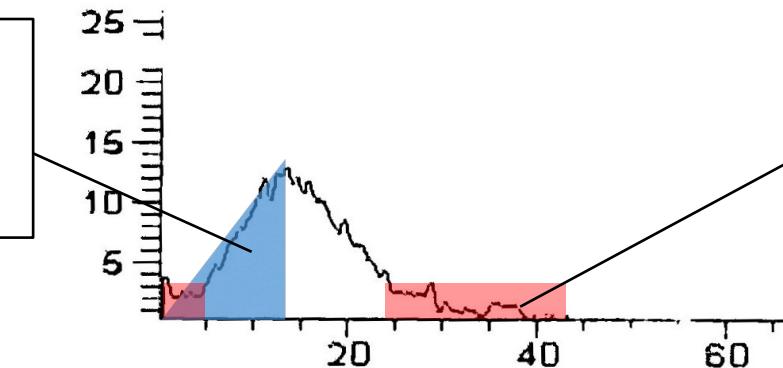


Backswing

尿流量が最後に最大値の20%に低下してから曲線が終了するまでの時間

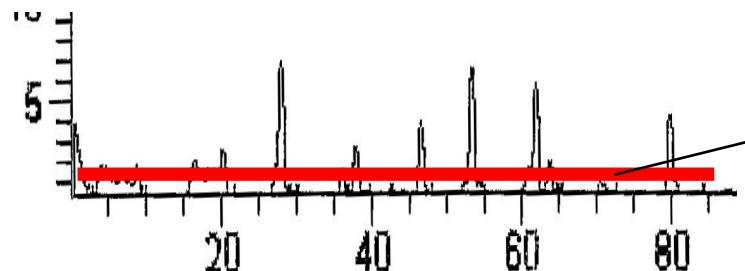
MaxTime

尿流量が最初に最大値に達した時間



TrickleTime

尿流量が最大20%未満になる時間



TRT(Times Reaching Trickle)

曲線が最大値の20%の線を横切る回数

うまくいかないので追加の特徴量も提案

医学的な特徴:

DeltaQ
(by VT, by FT)

PVR

統計的な特徴:

Backswing

Trickle Time

Max Time

TRT

Delay

VT

NEW

グラフ的な特徴:

Average degree

Average path length

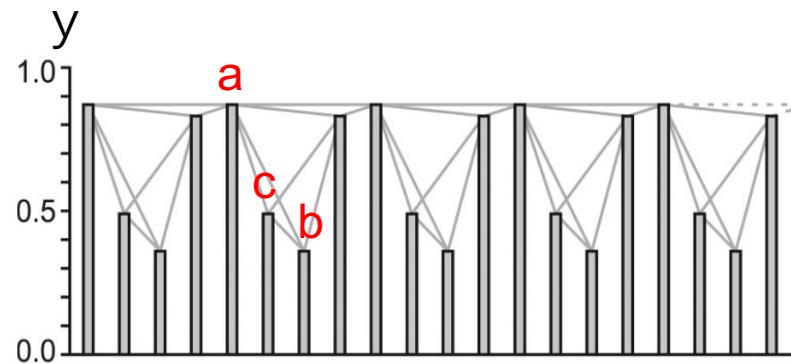
Clustering coefficient

Number of communities

Modularity

波形データから得られる特徴を示す新たなパラメータを提案
⇒可視性グラフの適用

- 可視性グラフ：平面内の点が相互に見えるかを示すグラフ
 - ノード：各ポイントの場所
 - エッジ：可視の接続（間に障害物が存在しない）
- a, b, c の点がある場合に、 a と b の間にエッジが存在する（=可視の状態）時は、右を満たす：
$$y_c < y_b + (y_a - y_b) \frac{t_b - t_c}{t_b - t_a}.$$



実験結果

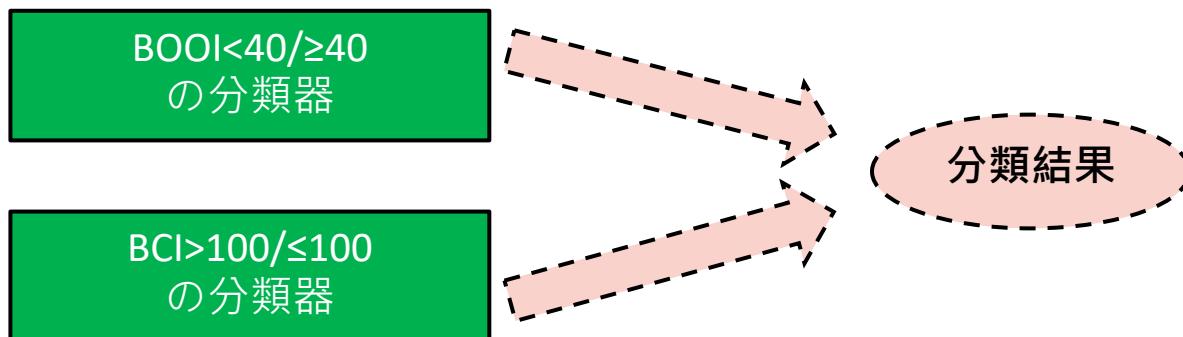
Dataset	パラメータ							精度
	Delta_Q	PVR	Delay	Backswing	Trickle Time	Maxtime	Times Reaching Trickle	
修正前	dq_vt	PVR	delay@20	bs@20		mt	trt@20	68.8%
	dq_vt		delay@halfavg	bs@halfavg	tt@halfavg	mt	trt@halfavg	69.6%
修正後	dq_vt	PVR	なし	bs@20	tt@20	mt	trt@20	70.6%
	dq_vt			bs@halfavg	tt@halfavg	mt	trt@halfavg	70.9%
	dq_ft			bs@20		mt	trt@20	70.9%
	dq_ft		なし	bs@halfavg	tt@halfavg	mt	trt@halfavg	71.4%
	dq_vt_integral			bs@halfavg	tt@20	mt	trt@halfavg	73.6%
	dq_ft_integral			bs@halfavg	tt@halfavg	mt	trt@halfavg	71.6%

期待できるほど高い性能を得られなかった

BCIとBOOIの値を予測する方法も検討

具体的な方法：

- UFMデータからBCIとBOOIの値を予測し、データを分類
- モチベーション：BCIとBOOIの値の範囲がわかれば、PFSデータでの診断のように直接病状がわかる



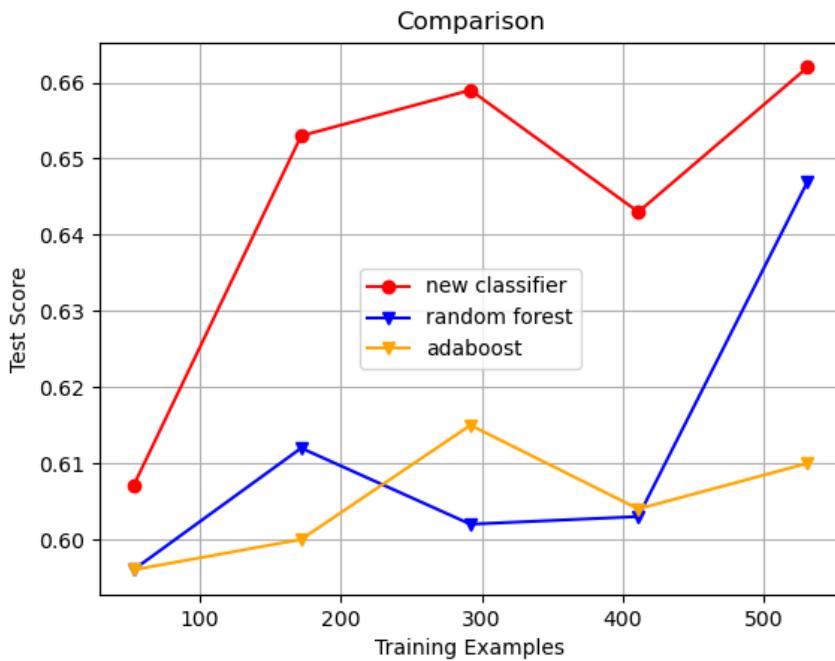
診断基準

PFSのデータ	タイプ
BCI>100, BOOI>40	BOO
BCI>100, BOOI<40	Normal
BCI<100, BOOI<40	DU
BCI<100, BOOI>40	MIX

使用した機械学習アルゴリズム：Random Forest Classifier, Adaboost, SVM (kernel function)

実験結果

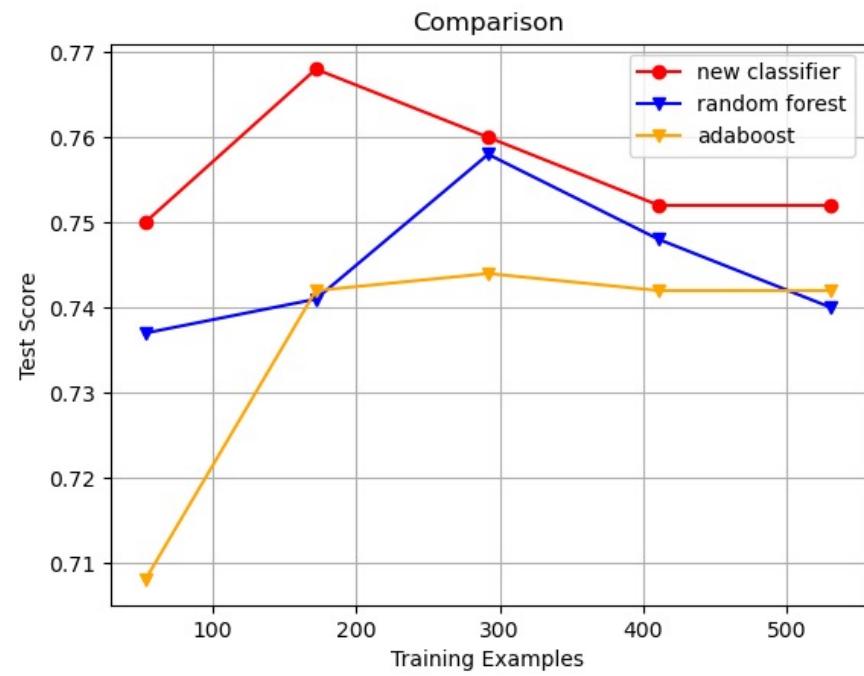
BCIの分類精度



- 新手法: 66.2%
- Random Forest: 64.7%
- Adaboost: 61.6%

期待できるほど高い性能を得られなかった

BOOIの分類精度



- 新手法: 76.8%
- Random Forest: 75.8%
- Adaboost: 74.3%



ご清聴ありがとうございました!